📈 나만의 데이터로 미래를 예측하다

Orange3 선형 회귀 실습 보고서

— 두 변수의 관계를 스스로 찾아 예측 모델 만들기 —

학년 반 번호		이름		제출일 . . .

🎯 미션 우리 주변에는 '하나가 늘면 다른 하나도 규칙적으로 변하는' 관계가 많습니다. 공부 시간과 성적, 기온과 아이스크림 판매량, 팔로워 수와 좋아요 수처럼요. 이번 활동에서는 내가 직접 고른 두 변수(x, y)의 데이터를 모아 산점도를 그리고, 노코딩 머신러닝(ML) 도구 Orange3로 선형 회귀 예측 모델을 만든 뒤, 그 예측이 믿을 만한지 스스로 검증합니다.

🏆 이 보고서는 수행평가① **"Orange3 선형회귀 탐구"** 입니다. 만점 **30**점 · 기본점수**9**점 세 영역 각 10점(영역1·영역2·영역3)으로 채점합니다. ※ **AI(생성형 AI 포함)** 활용은 원칙적으로 금지합니다.

영역 1	데이터 이해 및 회귀식 추정	[10점]

📋 평가요소 (배점 근거)

① 선형 관계가 나타나는 탐구 주제·데이터를 목적에 맞게 선정하고, 독립·종속 변수의 관계를 올바르게 파악하였는가? → 1-1

② 산점도를 근거로 회귀식(y=ax+b)을 합리적으로 추정하였는가? → 1-2-1·1-2-2

③ 기울기·절편의 의미를 데이터 맥락에서 설명하였는가? → 1-3

1-1 탐구 주제와 데이터 정하기 (내 탐구 설계)

💡 어떤 관계를 예측해 볼까? 아래는 아이디어일 뿐입니다. 관심 분야에서 자유롭게 골라도 좋고, 직접 새로운 주제를 만들어도 됩니다.

분야	예시 주제 (독립변수 x → 종속변수 y)
일상·소비	기온 → 아이스크림(또는 음료) 판매량 · 광고비 → 매출액
학습·생활	공부 시간 → 시험 점수 · 수면 시간 → 집중도 자기평가 점수
사회·미디어	팔로워 수 → 게시물 좋아요 수 · 영상 길이 → 조회수
과학·환경	음료 온도 → 얼음 녹는 시간 · 용수철에 매단 무게 → 늘어난 길이
스포츠·건강	키 → 몸무게 · 연습 시간 → 기록(초·점수)

✅ 좋은 데이터의 조건

· 두 변수 모두 숫자(연속형)이고, 하나가 변하면 다른 하나도 대체로 함께 변하는 관계일 것

· 데이터 개수는 최소 8개 이상 (많을수록 회귀선이 안정적)

· 직접 측정·설문하거나 공공데이터(KOSIS·기상자료개방포털 등)에서 수집 — 출처를 반드시 기록

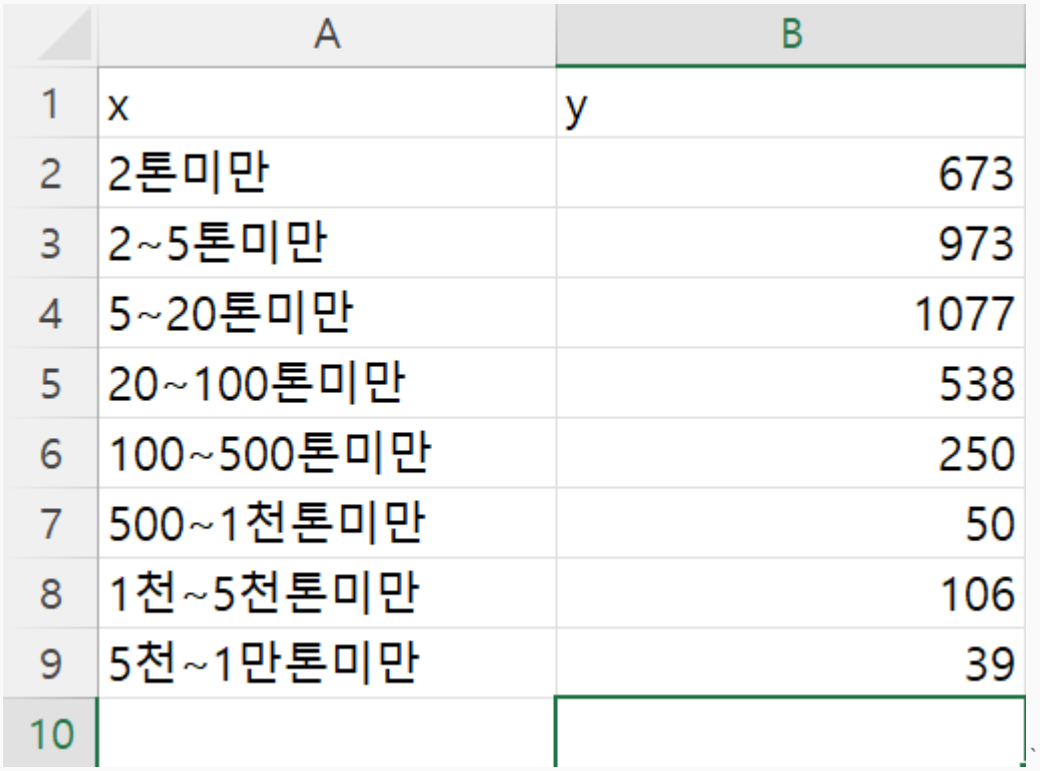
탐구 주제	사고종류별 선박총톤수별 해양사고 현황
독립변수 **x**	*총톤수*
종속변수 **y**	*사고 건수*
데이터 출처	*중앙해양안전심판원*
예상 관계	*X값이 커지면 y값도 커질것이다 왜냐하면 톤수 가 늘어날수록 사고위험이 올라가기 때문이다.*

1-2-1 내 훈련 데이터 입력하기 (train.csv)

💡 수집한 훈련 데이터를 구글 시트나 엑셀에 입력하고 train.csv로 저장하세요. 첫 행은 변수 이름(x, y)으로 합니다.

독립변수 **x** (_____)	종속변수 **y** (_____)
2톤미만	676
2~5톤 미만	973
5~20톤 미만	1077
20~100톤 미만	538
100~500톤 미만	250
500~1000톤 미만	50
1000~5000톤 미만	106
5000~1만톤 미만	39

📷 구글 시트 또는 엑셀에 입력한 훈련 데이터 화면을 캡처하여 붙여넣기



	A	B
1	x	y
2	2톤미만	673
3	2~5톤미만	973
4	5~20톤미만	1077
5	20~100톤미만	538
6	100~500톤미만	250
7	500~1천톤미만	50
8	1천~5천톤미만	106
9	5천~1만톤미만	39
10		

1-2-2 규칙을 찾아 회귀식 손으로 추정하기

🧠 x가 일정하게 커질 때 y는 얼마씩 변하나요? 표에서 규칙을 찾아 직선의 식 y = a x + b 로 손으로 추정해 보세요.

x가 한 단위 커질 때 y는 약 __90.6____만큼 (증가/감소)한다. → 기울기 a ≈ ___90.6___ , 절편 b ≈ ___763.6___ . 따라서 y = _-90.6_____ x + _763.6_____ 로 예상한다.

1-3 기울기와 절편의 의미 해석

데이터의 규칙은 없다 그래서 전체 평균 변화량을 구해서 나온값이 a=90.6 이다 그리고 x=0일때는 b=70.6 이다

영역 2 Orange3 예측 모델 구성 [10점]

📋 평가요소 (배점 근거)

① train-test 데이터를 적절히 구성하였는가? → 1-2(train)·2-1(test)

② 워크플로우(File→Scatter Plot→Linear Regression→Predictions)를 올바르게 연결하였는가? → 2-2

③ 모델의 예측값을 산출하고 실제값(손 계산)과 비교하였는가? → 2-3

2-1 내 테스트 데이터 만들기 (test.csv)

💡 훈련 데이터 범위 안에서 x값 5개 정도를 골라 테스트 데이터(test.csv)를 만드세요. y열은 비워 둡니다.

독립변수 **x**	종속변수 **y** (비움)
2톤	?
4톤	?
40톤	?
200톤	?
750톤	?

2-2 Orange3 워크플로우 구성하기

📌 워크플로우 순서

① File 위젯 → train.csv 불러오기 (이름: train data)

② Data Table 위젯 연결 → 데이터 확인

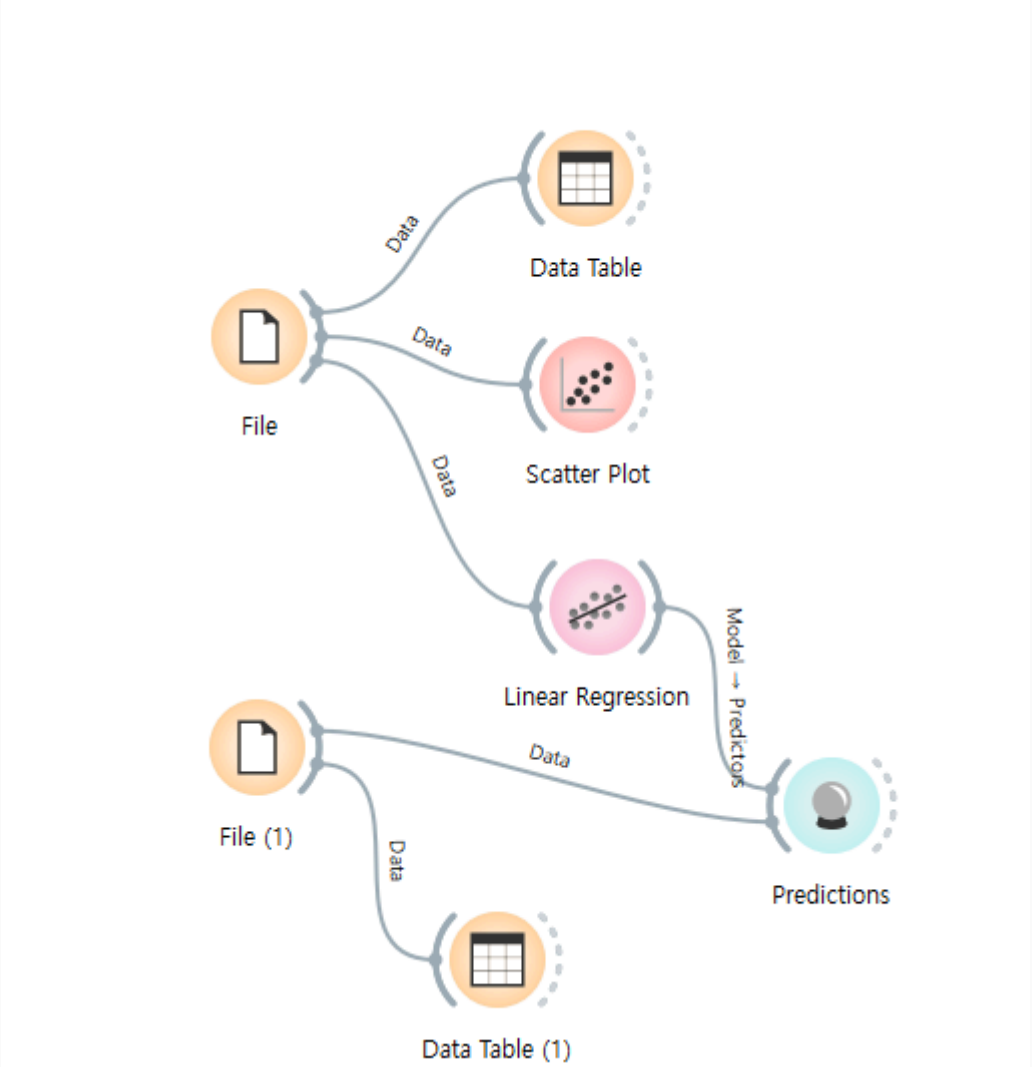
③ Scatter Plot 위젯 연결 → 산점도 확인 (x축: 독립변수, y축: 종속변수)

④ Linear Regression 위젯 연결 → 모델 학습

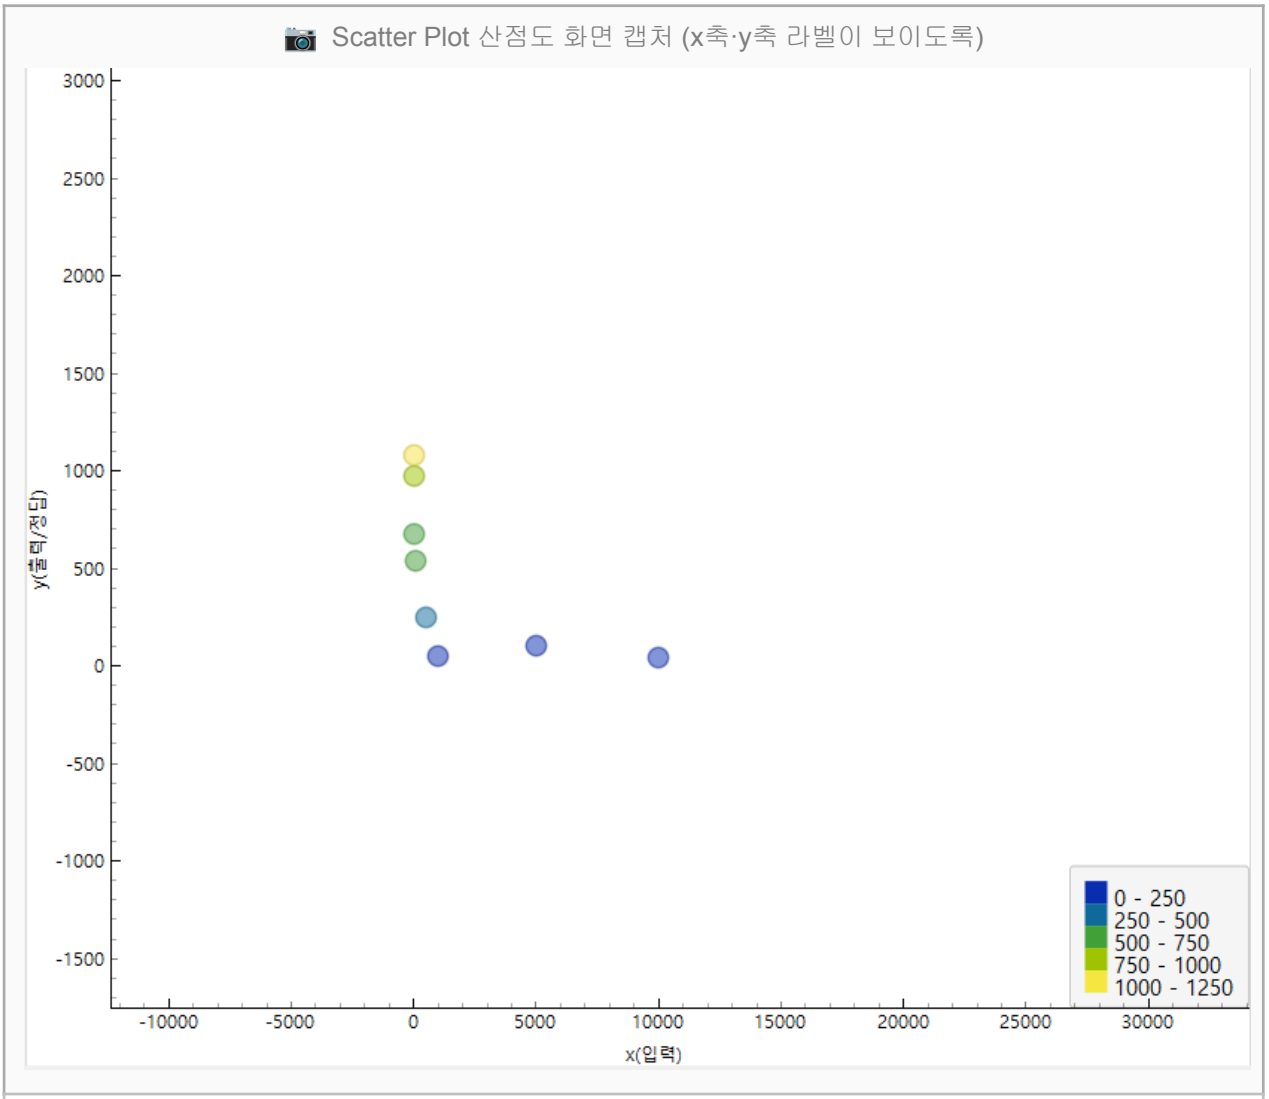
⑤ 새 File 위젯 → test.csv 불러오기 (이름: test data)

⑥ Predictions 위젯 → 모델 + 테스트 데이터 연결

📷 Orange3 캔버스의 전체 워크플로우를 캡처



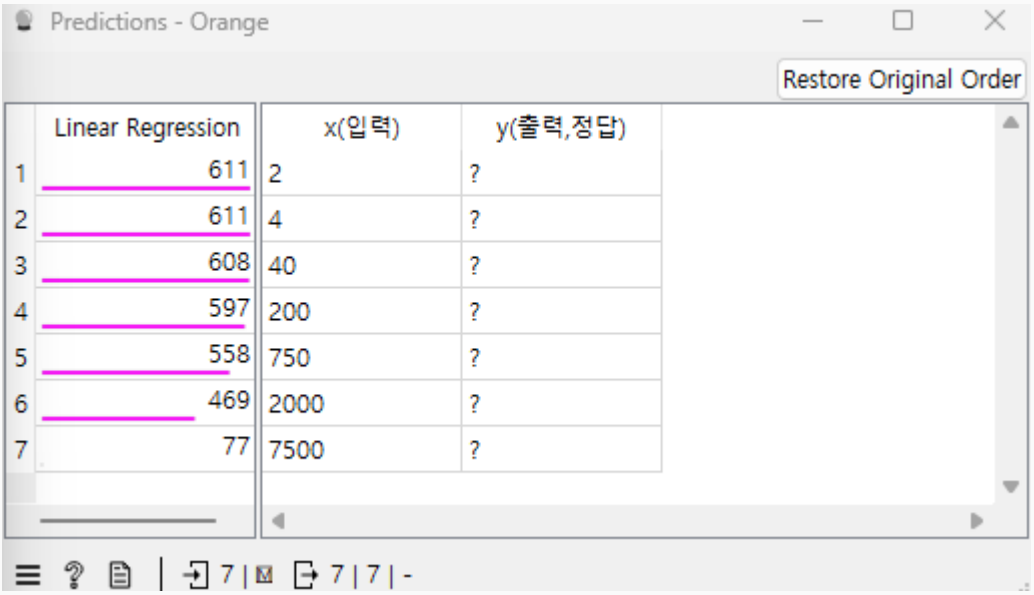
산점도 확인 및 관찰



데이터 점들은 대부분 ㄴ 모양으로 분포 했다 또한 음의 방향이고 직선경향의 강도는 약하다

2-3 예측 결과 비교 **(**내 손 계산 **vs Orange3)**

📷 Predictions 위젯의 예측 결과 화면을 캡처



x 값	내가 계산한 예측값 (y=ax+b)	Orange3 예측값
2	944.6	611
4	1.126	611
40	4.387.6	608
200	18.833.6	597
750	68.713.6	558

영역 3 결과 검증 및 해석 [10점]

📋 평가요소 (배점 근거)

① 회귀선과 평가지표(R²·MAE·RMSE)로 예측 결과의 타당성을 검증하였는가? → 3-1

② 정비례·반비례 등 관계의 방향과 의미를 데이터 맥락에서 해석하였는가? → 3-2

③ 모델의 한계(외삽의 위험)를 탐구하고, 활동을 통해 배운 점을 성찰하였는가? → 3-3·3-4

3-1 회귀선으로 타당성 검증

내가 계산한 값이랑 오렌지3가 계산한 값이 달랐다 값이 너무 차이가 난다

*예) **x=2** 내가계산한 값:**944.6** 오렌지:**611***

3-1-2 모델 평가지표로 신뢰도 검증 (Test and Score · 심화)

🌟 **(심화) Test and Score**로 모델의 신뢰도를 '숫자'로 검증하기

① **[Evaluate] → [Test and Score]** 위젯을 추가한다.

② **train data(File)**를 **Data**로, **Linear Regression**을 **Learner**로 각각 연결한다.

③ 평가 방법은 **Cross validation(**교차검증**,** 기본값**)**으로 두고 아래 세 지표를 읽어 기록한다**.**

(MSE·MAPE도 함께 나오지만 **R²·MAE·RMSE**에 집중**. RMSE = MSE**의 제곱근**)**

평가지표	내가 기록한 값	이 값이 뜻하는 것 **(**내 해석**)**
R² (결정계수)	-0....	데이터가 정확하지 않음
MAE (평균오차)	33....	실제값과 예측값의 차이가 33정도 차이남
RMSE	401....	평균오차가 크다

위 지표로 볼 때 내 모델은 얼마나 믿을 만한가요? 아래를 근거로 설명하세요.

① R²는 1에 얼마나 가까운가? (예측이 데이터를 잘 설명하는가)

R²는, 0보다 작은 음수가 나왔다 그러므로 선형회귀 데이터는 거의 정확하지가 않다

② RMSE가 MAE보다 크다면, 그 이유는 무엇일까? (크게 빗나간 이상치)

RMSE(401.....)가 MAE(33....)보다 훨씬 크게 나타났다 차이가 크것은 대부분의 값은 오차가 작지만 일부 데이터는 값이 크게 나온다는 것이다 앞에 자료에서 x=2일 때 계산값 944.6 , Orange 예측 611처럼 큰 차이가 난다

③ [심화] Test and Score 점수는 '처음 보는 데이터로 시험 본' 교차검증 점수입니다. 전체 데이터에 그냥 맞췄을 때(훈련)보다 왜 조금 낮을까요?

R²가 음수로 나온 이유는 데이터 개수가 8개로 적고 x와 y 도 곡선에 가깝기 때문이다. 그래서 교차검증을 할 때 예측하는 과정에서 오차가 크게 벌어진 것 같다

3-2 결과 해석 — 숫자 뒤의 의미

x와 y는 정비례·반비례 중 어느 관계인가요? 기울기의 크기가 뜻하는 바는? 이 예측 결과를 실생활에서 어떻게 활용할 수 있을지 내 주제의 맥락으로 해석하세요.

x랑y는 반비례 관계다 왜냐하면 x가 커질수록 y 의 값이 작아지기 때문이다 다만 R² 와 RMSE 의 값을 보 직선보다 곡선에 더 가까운 모양이라 정확히 설명하기는 어렵다 이를 실생활에 적용을 하면 소형구간에는 조심스럽게 다루어야하고 큰대형 구간에서는 예측값이 일정하므로 안정적으로 활용할수 있을것 같다 하지만 실제로 활용을 할려면 데이터을 조금 더 모으거나 다시 분석해 활용해야 할것 같다

3-3-1 한계 탐구 — 극단값 실험 **(**외삽의 위험**)**

🤔 학습 데이터 범위를 크게 벗어난 x값을 회귀식에 넣으면 예측이 현실적으로 말이 될까요?

외삽(Extrapolation)의 위험을 확인해 봅시다.

극단적인 **x** 값	모델 예측값 **y**	현실적으로 가능한가**?**

200	597	사용할수는 있지만 신뢰하기에는 어렵다
750	558	사용할수는 있지만 값이 크게 나온다

극단값에서 예측이 현실과 맞지 않는(또는 맞는) 이유를 설명하세요. 선형 회귀는 어떤 범위에서 신뢰할 수 있을까요?

앞서 자료에서 알수있듯 x=200 y=750 이다 이 범위에서 예측한 값이 맞지 않을수 있다 왜냐하면 x와y 관계 모양이 직선이 아닌 곡선 모양이가 때문이다 이로인해 데이터가 어긋난다 그리고 신뢰할수 있는 범위는 훈련데이터 범위안 그리고 이 안에서 x와 y 관계가 직선에 가까울때는 신뢰 할수있다

3-3-2 활동 성찰

📝 활동을 돌아보며 이번 활동에서 '어떤 문제 → 어떻게 해결 → 무엇을 배웠는지'와, 선형 회귀로 예측할 때 주의할 점(3-3의 외삽 실험과 연결)을 함께 정리하세요. 성실히 쓰면 세특(세부능력 및 특기사항) 작성의 좋은 소재가 됩니다.

📝 활동 성찰 — '어떤 문제 → 어떻게 해결 → 무엇을 배웠는지' 흐름으로 쓰면 세특 작성의 좋은 소재가 됩니다.

수행평가를 하면서 어려움을 겪었던 것은 오렌지3(데이터 분석) 과정에서 여러 시행착오를 겪었던 것이다 이를 해결하기 위해 원인을 살피던중 File 위젯에서 x 데이터의 Role에 feature가 아니라 meta로 잘못 설정해서 문제가 발생했다 그래서 feature로 바꿨다 또 다른 시행착오 로는 훈련 데이터와 실전 데이터를 연결한 다음 Predictions 위젯을 클릭했데 오류가 발생했다 원인을 찾아보니 두 데이터의 이름이 서로 달랐다 [x(입력),x]/ [2톤미만/ 2톤]의 표기가 같지가 않았다 이를해결하기 위해 두 엑셀 파일명을 수정했다

📚 핵심 개념 요약

· 지도학습 : 정답(레이블)이 있는 데이터로 모델을 훈련시키는 방법

· 회귀(Regression) : 연속적인 숫자 값을 예측하는 문제 유형

· 선형 회귀 : y = ax + b 직선으로 데이터의 패턴을 표현하는 알고리즘

· 기울기 a의 부호 : a>0이면 양의 관계(정비례), a<0이면 음의 관계(반비례)

· 외삽(Extrapolation)의 위험 : 학습 데이터 범위를 벗어난 예측은 신뢰하기 어려움

· 결정계수(R^2) : 모델이 데이터를 설명하는 비율(0~1). 단순 선형회귀에서는 상관계수의 제곱($R^2=r^2$)

· MAE / RMSE : 예측 오차의 크기(작을수록 좋음). RMSE는 큰 오차(이상치)에 더 민감

· 교차검증(Cross validation) : 데이터를 나눠, 학습에 쓰지 않은 부분으로 평가 → 모델의 '진짜 실력(일반화 성능)' 측정

· 훈련 vs 검증 성능 : 본 데이터엔 잘 맞고(훈련), 처음 보는 데이터엔 조금 못 맞음(검증). Test and Score 값이 검증 성능

🔎 수행평가 채점표 (교사 기입용)

채점 기준: 아래 참고

※ 저작권·데이터 윤리 미준수, 평가 윤리 미준수, AI 활용 금지 원칙 위반 등 부적절 상황 발생 시 해당 영역 0점 처리.

평가영역	배점	채점 기준 (해당 점수에 ○)	획득 점수
[영역1] 데이터 이해 및 회귀식 추정	10점	10 · 8 · 6 · 4	
[영역2] Orange3 예측 모델 구성	10점	10 · 8 · 6 · 4	
[영역3] 결과 검증 및 해석	10점	10 · 7 · 4 · 1	
합계	**30**점	기본점수 9점	**/ 30**